PROPOSAL PENELITIAN

PREDIKSI HARGA XAG/USD H4: PERBANDINGAN LSTM DAN XGBOOST DENGAN INDIKATOR TEKNIKAL DAN ICHIMOKU KINKO HYO

Oleh:

Shahzada Sabih Anandian Hartanto
NPM 23081010209

PROGRAM STUDI INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN"
JAWA TIMUR

2026

ABSTRAK

Perak (XAG/USD) adalah komoditas dengan karakter ganda, yaitu sebagai logam mulia sekaligus logam industri, sehingga harganya sangat fluktuatif dan sulit diprediksi. Penelitian-penelitian prediksi harga logam mulia umumnya memakai data harian dan harga historis murni, sementara indikator teknikal yang dipakai praktisi seperti Ichimoku Kinko Hyo dan Bulls & Bears Power (Elder Ray) belum banyak dievaluasi sebagai fitur pada model *machine learning*, khususnya untuk perak. Penelitian ini mengusulkan perbandingan model *Long Short-Term Memory* (LSTM) dan *Extreme Gradient Boosting* (XGBoost) untuk memprediksi harga XAG/USD pada timeframe H4 dengan dua skenario fitur: (A) indikator konvensional (Moving Average, RSI, MACD, Bulls & Bears Power) dan (B) skenario A ditambah lima komponen Ichimoku Kinko Hyo. Dataset berupa 11.690 bar H4 (Januari 2011 – Juni 2018) yang dibangun dari data tick Dukascopy. Evaluasi memakai MAE, RMSE, MAPE, akurasi arah, dan perbandingan terhadap *baseline* naive dengan uji Diebold–Mariano, serta analisis kontribusi indikator melalui *feature importance*.

Kata kunci: XAG/USD, prediksi harga, LSTM, XGBoost, Ichimoku Kinko Hyo, Elder Ray, H4.

ABSTRACT

Silver (XAG/USD) has a dual character as both a precious and an industrial metal, which makes its price highly volatile and difficult to predict. Studies on precious-metal price prediction mostly rely on daily data and historical prices alone, whereas technical indicators used by practitioners, such as Ichimoku Kinko Hyo and Bulls & Bears Power (Elder Ray), have rarely been evaluated as machine-learning features, particularly for silver. This study proposes a comparison of Long Short-Term Memory (LSTM) and Extreme Gradient Boosting (XGBoost) models for predicting the XAG/USD price on the H4 timeframe under two feature scenarios: (A) conventional indicators (Moving Average, RSI, MACD, Bulls & Bears Power) and (B) scenario A plus the five components of Ichimoku Kinko Hyo. The dataset consists of 11,690 H4 bars (January 2011 – June 2018) built from Dukascopy tick data. Evaluation uses MAE, RMSE, MAPE, directional accuracy, and a comparison against a naive baseline with the Diebold–Mariano test, complemented by a feature-importance analysis of indicator contributions.

Keywords: XAG/USD, price prediction, LSTM, XGBoost, Ichimoku Kinko Hyo, Elder Ray, H4.

DAFTAR ISI

ABSTRAK ..... **ii**
ABSTRACT ..... **iii**
DAFTAR TABEL ..... **v**
DAFTAR GAMBAR ..... **vi**
BAB I PENDAHULUAN **1**
1.1 Latar Belakang 1
1.2 Rumusan Masalah 2
1.3 Tujuan Penelitian 2
1.4 Hipotesis 3
1.5 Batasan Masalah 3
1.6 Manfaat Penelitian 4
1.7 Sistematika Penulisan 4
BAB II TINJAUAN PUSTAKA **5**
2.1 XAG/USD dan Efisiensi Pasar 5
2.2 Indikator Teknikal 5
2.3 LSTM 5
2.4 XGBoost 6
2.5 Penelitian Terdahulu 6
BAB III METODOLOGI PENELITIAN **7**
3.1 Desain Penelitian 7
3.2 Dataset 8
3.3 Rekayasa Fitur 8
3.4 Variabel Target 9
3.5 Pembagian Data 9
3.6 Model dan Hyperparameter 10
3.7 Evaluasi 10
3.8 Hasil Pilot (Uji Kelayakan Pipeline) 11
3.9 Alat dan Lingkungan 11
3.10 Jadwal Penelitian (Usulan) 12
3.11 Risiko dan Mitigasi 12
DAFTAR PUSTAKA **13**

DAFTAR TABEL

Tabel 1.1. Hipotesis penelitian 3
Tabel 2.1. Indikator teknikal yang digunakan 5
Tabel 3.1. Ringkasan dataset penelitian 8
Tabel 3.2. Rekayasa fitur pada skenario A dan B 8
Tabel 3.3. Pembagian data latih, validasi, dan uji 9
Tabel 3.4. Konfigurasi model dan rencana penyetelan hyperparameter 10
Tabel 3.5. Jadwal penelitian (usulan) 12
Tabel 3.6. Risiko penelitian dan mitigasinya 12

DAFTAR GAMBAR

Gambar 3.1. Alur penelitian 7

Gambar 3.2. Harga close XAG/USD H4 beserta pembagian data kronologis (train, validasi, test) dan distribusi log-return 10

BAB I
PENDAHULUAN

1.1 Latar Belakang

Perak (XAG/USD) diperdagangkan sebagai logam mulia dan sekaligus dipakai luas sebagai bahan baku industri. Karena dipengaruhi dua kelompok faktor tersebut, yaitu sentimen aset lindung nilai dan permintaan industri, harga perak cenderung lebih fluktuatif dibanding emas. Prediksi harga yang akurat bernilai bagi trader, investor, maupun pelaku industri, tetapi pasar keuangan juga dikenal sulit diprediksi karena harga mencerminkan informasi yang tersedia [23]. Konsekuensinya, setiap model prediksi perlu dibandingkan dengan *baseline* sederhana (harga tidak berubah) agar klaim akurasinya bermakna.

Penelitian prediksi harga perak berbasis *machine learning* sudah ada tetapi jumlahnya terbatas. Gono dkk. menerapkan XGBoost untuk prediksi harga perak [1], Gür membandingkan CNN, LSTM, GRU, dan model hibrida pada harga perak [2], dan Jin dan Xu memakai *Gaussian process regression* [3]. Studi yang lebih luas pada minyak mentah, emas, dan perak [4], pada emas dengan XGBoost dan SHAP [5], serta pada XAU/USD dengan LSTM yang dioptimasi [6] dan LSTM-autoencoder [7] menunjukkan bahwa model *tree ensemble* dan *deep learning* sama-sama kompetitif. Di Indonesia, riset prediksi harga emas dengan LSTM, GRU, dan SVR cukup banyak [12]–[15], tetapi dari literatur yang berhasil ditinjau, penelitian lokal yang khusus membahas XAG/USD sangat sedikit, dan sebagian besar memakai harga historis harian tanpa indikator teknikal.

Di sisi lain, praktisi memakai indikator teknikal seperti Ichimoku Kinko Hyo, RSI, MACD, dan Bulls & Bears Power (Elder Ray) [18], [19]. Ichimoku di literatur lokal baru diteliti sebagai aturan perdagangan manual pada pasar forex dan saham [9]–[11], dan di literatur internasional sebagian besar sebagai aturan berbasis dukungan–resistensi [8]. Dari tinjauan yang dilakukan, belum ditemukan studi yang memasukkan Ichimoku dan Elder Ray sebagai fitur pada model LSTM maupun XGBoost untuk harga perak. Selain itu, mayoritas studi memakai data harian, sedangkan timeframe H4 yang lazim dipakai trader menyediakan observasi jauh lebih banyak.

Berdasarkan celah tersebut, penelitian ini membandingkan LSTM [16] dan XGBoost [17] untuk memprediksi harga XAG/USD timeframe H4 dengan dua skenario fitur: (A) indikator konvensional dan (B) indikator konvensional ditambah Ichimoku Kinko Hyo. Rancangan eksperimen 2×2 ini memungkinkan pengukuran langsung kontribusi Ichimoku, dan semua model dibandingkan terhadap *baseline* naive dengan uji signifikansi statistik [20]. Analisis fundamental (berita, kalender ekonomi, CPI) sengaja tidak dilibatkan agar penelitian terfokus pada analisis teknikal.

1.2 Rumusan Masalah

1. Bagaimana performa model LSTM dan XGBoost dalam memprediksi harga XAG/USD timeframe H4 berbasis indikator teknikal dibandingkan *baseline* naive?
2. Apakah penambahan lima komponen Ichimoku Kinko Hyo meningkatkan akurasi prediksi dibanding indikator konvensional saja (Moving Average, RSI, MACD, Bulls & Bears Power)?
3. Model mana yang lebih unggul antara LSTM dan XGBoost, dan apakah perbedaannya signifikan secara statistik?
4. Indikator atau komponen indikator apa yang paling berkontribusi terhadap prediksi?
5. *(Tahap lanjutan, UAS)* Bagaimana konsistensi hasil pada data baru melalui *forward testing* di akun demo?

1.3 Tujuan Penelitian

1. Membangun dan mengevaluasi model LSTM dan XGBoost untuk prediksi harga XAG/USD H4.
2. Mengukur kontribusi Ichimoku Kinko Hyo melalui uji ablasi skenario A vs B.
3. Membandingkan LSTM dan XGBoost secara adil (fitur, data, dan pembagian data identik) dengan uji signifikansi.
4. Mengidentifikasi indikator paling berpengaruh melalui analisis *feature importance*.

5. Memvalidasi hasil pada data baru melalui *forward testing* di akun demo (tahap lanjutan).

1.4 Hipotesis

Tabel 1.1. Hipotesis penelitian

No	H_0 (nol)	H_1 (alternatif)
1	Akurasi model tidak berbeda dari *baseline* naive	Model lebih akurat dari naive
2	Skenario B (dengan Ichimoku) tidak lebih akurat dari skenario A	Skenario B lebih akurat dari skenario A
3	LSTM dan XGBoost memiliki akurasi yang sama	Salah satu model lebih akurat

Pengujian memakai uji Diebold–Mariano dengan koreksi Holm (lihat dokumen *Rencana Evaluation Metric*). Hasil yang menolak maupun yang gagal menolak H_0 sama-sama dilaporkan sebagai temuan.

1.5 Batasan Masalah

1. Instrumen: XAG/USD, timeframe H4, data historis Januari 2011 – Juni 2018 (11.690 bar).
2. Fitur: Moving Average, RSI, MACD, Bulls & Bears Power, dan lima komponen Ichimoku Kinko Hyo. Bollinger Bands tidak digunakan.
3. Analisis fundamental (berita, kalender ekonomi, CPI, sentimen) tidak dilibatkan.
4. Model: LSTM dan XGBoost. Prediksi satu langkah ke depan (bar H4 berikutnya).
5. Validasi utama berupa pengujian *hold-out* kronologis. *Forward testing* di akun demo dilakukan pada tahap lanjutan. Pengujian di akun real berada di luar cakupan riset kecil ini.
6. Penelitian ini bukan rekomendasi investasi dan tidak mengklaim profitabilitas.

1.6 Manfaat Penelitian

- **Akademik:** mengisi celah literatur prediksi XAG/USD, menyediakan evaluasi terkontrol atas kontribusi Ichimoku dan Elder Ray pada model *machine learning*, serta dataset dan kode yang dapat direproduksi.
- **Praktis:** memberi bukti empiris bagi trader apakah indikator yang lazim dipakai benar-benar memberi nilai prediktif di atas *baseline* sederhana.

1.7 Sistematika Penulisan

Proposal ini disusun dalam tiga bab. **Bab I Pendahuluan** memuat latar belakang, rumusan masalah, tujuan, hipotesis, batasan masalah, manfaat, dan sistematika penulisan. **Bab II Tinjauan Pustaka** memuat landasan teori tentang XAG/USD, indikator teknikal, LSTM, XGBoost, dan penelitian terdahulu. **Bab III Metodologi Penelitian** memuat desain eksperimen, dataset, rekayasa fitur, variabel target, pembagian data, model, evaluasi, hasil pilot, alat, jadwal, serta risiko dan mitigasinya. Bab IV Hasil dan Pembahasan serta Bab V Penutup akan disusun setelah eksperimen selesai.

BAB II
TINJAUAN PUSTAKA

2.1 XAG/USD dan Efisiensi Pasar

XAG/USD adalah harga satu *troy ounce* perak dalam dolar AS. Menurut hipotesis pasar efisien, harga telah mencerminkan informasi yang tersedia sehingga sulit diprediksi [23]. Karena itu, *baseline* naive (prediksi harga bar berikutnya sama dengan harga saat ini) menjadi pembanding yang wajib, dan temuan bahwa model tidak mengalahkan naive tetap merupakan hasil ilmiah yang sah.

2.2 Indikator Teknikal

Tabel 2.1. Indikator teknikal yang digunakan

Indikator	**Rumus ringkas**	**Fungsi**
Simple Moving Average	$SMA_n = (1/n)\ \Sigma_{i=0}^{n-1}\ C_{t-i}$	Arah tren
RSI (Wilder, n = 14)	RSI = 100 − 100 / (1 + RS), dengan RS = (rata-rata kenaikan) / (rata-rata penurunan)	Momentum, *overbought*/*oversold* [18]
MACD	$MACD = EMA_{12}(C) - EMA_{26}(C)$; sinyal = EMA_9(MACD)	Momentum dan perubahan tren
Bulls Power	$H_t - EMA_{13}(C)_t$	Kekuatan pembeli [19]
Bears Power	$L_t - EMA_{13}(C)_t$	Kekuatan penjual [19]
Tenkan-sen	$(HH_9 + LL_9) / 2$	Garis konversi Ichimoku
Kijun-sen	$(HH_{26} + LL_{26}) / 2$	Garis dasar Ichimoku
Senkou Span A	(Tenkan + Kijun) / 2, digeser 26 bar ke depan	Batas awan
Senkou Span B	$(HH_{52} + LL_{52}) / 2$, digeser 26 bar ke depan	Batas awan
Chikou Span	C_t digambar 26 bar ke belakang	Konfirmasi tren

HH/LL = harga tertinggi/terendah n bar terakhir.

2.3 LSTM

Long Short-Term Memory adalah arsitektur *recurrent neural network* dengan gerbang *input*, *forget*, dan *output* yang mampu menangkap dependensi

jangka panjang pada data sekuensial [16]. LSTM banyak dipakai pada prediksi harga komoditas [2], [12]–[15].

2.4 XGBoost

XGBoost adalah implementasi *gradient boosted decision trees* yang efisien dengan regularisasi dan penanganan *sparsity* [17]. Model ini cepat dilatih, bekerja pada fitur tabular, dan menyediakan *feature importance* yang memudahkan interpretasi [1], [5].

2.5 Penelitian Terdahulu dan Research Gap

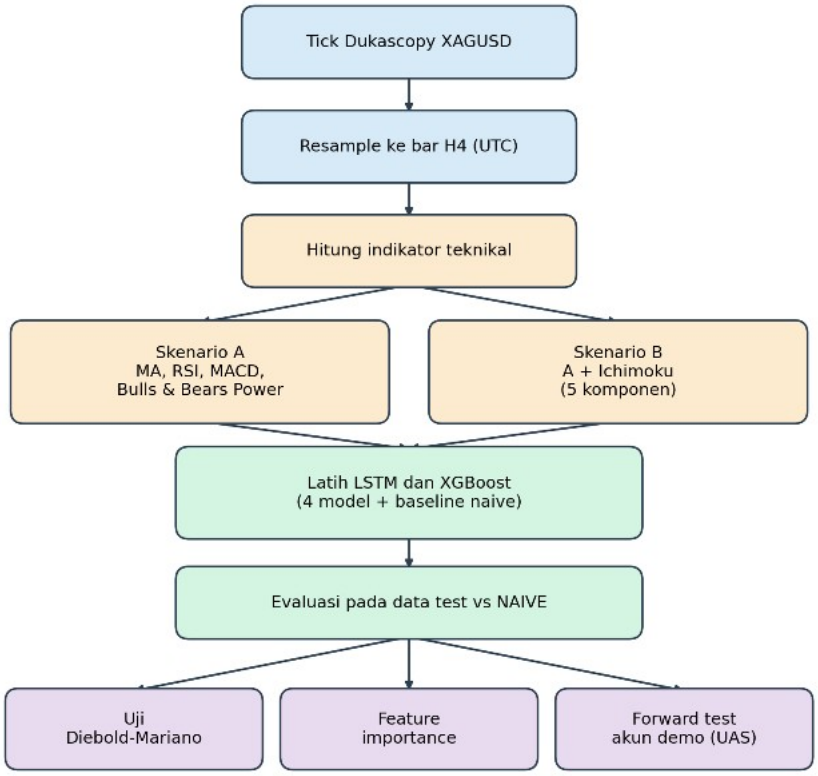
Peta literatur disusun dari penelusuran terarah (Google Scholar, Springer, ScienceDirect, MDPI, portal jurnal SINTA) pada tingkat abstrak/ringkasan. Empat studi paling dekat dengan topik ini adalah Gono dkk. [1] (XGBoost, harga perak harian), Gür [2] (CNN/LSTM/GRU/hibrida, harga perak), Jin dan Xu [3] (Gaussian process regression, harga perak), serta studi emas dan logam mulia [4]–[7] dan lokal [12]–[15]; kajian Ichimoku [8]–[11] berbasis aturan manual.

Dari literatur yang ditinjau teridentifikasi empat celah: **G1 (Aset)** — prediksi harga perak berbasis *machine learning* masih sedikit dan riset lokal yang membahas XAG/USD hampir tidak ditemukan; **G2 (Fitur)** — Ichimoku Kinko Hyo dan Bulls & Bears Power belum dievaluasi sebagai fitur model LSTM/XGBoost untuk perak; **G3 (Desain komparasi)** — belum ada studi yang membandingkan LSTM dan XGBoost dengan fitur identik disertai uji ablasi, *baseline* naive, dan uji signifikansi; **G4 (Timeframe)** — studi yang ditinjau umumnya memakai data harian, bukan H4. Penelitian ini menjawab keempat celah tersebut sekaligus.

BAB III
METODOLOGI PENELITIAN

3.1 Desain Penelitian

Penelitian eksperimental kuantitatif dengan rancangan 2×2: dua model (LSTM, XGBoost) × dua skenario fitur (A, B), ditambah *baseline* naive sebagai pembanding.



Gambar 3.1. Alur penelitian

3.2 Dataset

Tabel 3.1. Ringkasan dataset penelitian

Atribut	**Nilai**
Instrumen / timeframe	XAG/USD, H4 (UTC)
Sumber	Tick historis Dukascopy Bank SA, melalui mirror publik FX-Data [22]
Periode	20 Januari 2011 – 19 Juni 2018
Jumlah bar	11.690 (memenuhi syarat minimal 10.000)
Kolom	time, open, high, low, close, tick_volume, avg_spread
Lokasi	02-Dataset/xagusd_h4_2011_2018.csv
Kualitas data	0 duplikat waktu, 0 nilai kosong, 0 pelanggaran konsistensi OHLC (low ≤ open, close ≤ high)
Keterbatasan utama	Data uji berada pada rezim volatilitas rendah (16–18 USD), berbeda dari data latih yang bergejolak; harga mid, bukan harga eksekusi

Detail pembuatan, pemeriksaan kualitas, dan keterbatasan data ada di **02-Dataset/README.md**. Rencana perluasan: data Juni 2018 – 2026 disambungkan menggunakan skrip **02-Dataset/extend_dataset_2026.py** (sumber Dukascopy, dengan validasi pada periode tumpang-tindih) pada tahap lanjutan; skrip sudah siap tetapi belum dijalankan pada data nyata.

3.3 Rekayasa Fitur

Semua fitur dibuat *scale-free* (dibagi harga *close*) agar model tidak terganggu ketika harga mencapai level yang belum ada di data latih.

Tabel 3.2. Rekayasa fitur pada skenario A dan B

Kelompok	**Fitur**	**Skenario A**	**Skenario B**
Dasar	ret_1 (log-return bar sebelumnya)	✓	✓
Moving Average	sma20_dist, sma50_dist, sma20_50_diff	✓	✓
RSI	rsi14	✓	✓
MACD	macd, macd_signal, macd_hist	✓	✓
Bulls & Bears Power	bull_power, bear_power	✓	✓
Ichimoku	tenkan_dist, kijun_dist, spanA_dist, spanB_dist, chikou_diff	–	✓

Pencegahan kebocoran data (*data leakage*). Pada grafik, Chikou Span digambar dengan menggeser *close* 26 bar ke belakang, yang berarti memakai data masa depan. Pada penelitian ini fitur Chikou didefinisikan sebagai selisih antara *close* sekarang dan *close* 26 bar lalu, yang secara makna sama dengan sinyal Chikou namun hanya memakai informasi masa lalu. Awan Ichimoku pada bar saat ini diambil dari hasil hitungan 26 bar sebelumnya.

3.4 Variabel Target

Target adalah *log-return* bar berikutnya, $r_{t+1} = \ln(C_{t+1}/C_t)$. Harga diprediksi dengan rekonstruksi $\hat{C}_{t+1} = C_t \cdot \exp(\hat{r}_{t+1})$, sehingga metrik tetap dihitung dalam satuan harga. Alasannya, model berbasis pohon tidak dapat mengekstrapolasi ke rentang harga di luar data latih, padahal perak melewati rentang harga yang sangat lebar.

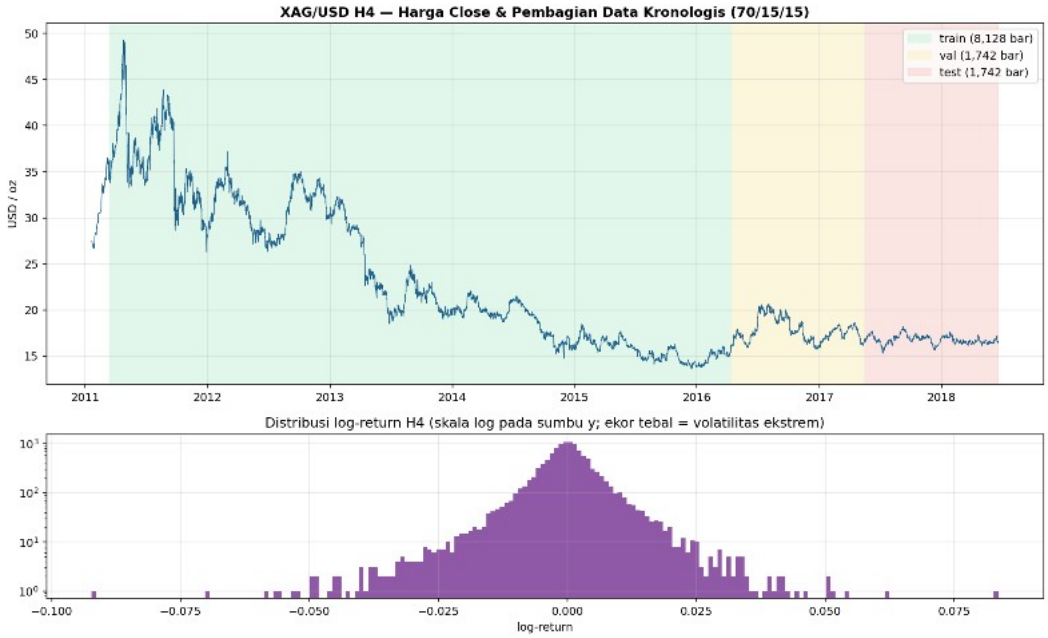
3.5 Pembagian Data

Pembagian kronologis (bukan acak) untuk mencegah informasi masa depan bocor ke data latih.

Tabel 3.3. Pembagian data latih, validasi, dan uji

Subset	**Rentang**	**Jumlah**
Train (70%)	15 Mar 2011 – 14 Apr 2016	8.128
Validasi (15%)	14 Apr 2016 – 17 Mei 2017	1.742
Test (15%)	17 Mei 2017 – 19 Jun 2018	1.742

Sebanyak 78 bar awal hilang karena periode pemanasan indikator (Ichimoku memerlukan 52 + 26 bar). Penskalaan fitur untuk LSTM dilatih hanya pada data *train*.



Gambar 3.2. Harga close XAG/USD H4 beserta pembagian data kronologis (train, validasi, test) dan distribusi log-return

3.6 Model dan Hyperparameter

Tabel 3.4. Konfigurasi model dan rencana penyetelan hyperparameter

Model	**Konfigurasi awal**	**Rencana penyetelan**
LSTM	1 lapisan LSTM 64 unit, *dropout* 0,2, Adam (lr 1e-3), *batch* 64, jendela 48 bar (8 hari), *early stopping* sabar 5	*Random search* pada data validasi (unit, jendela, *dropout*, lr); 5 *seed* acak
XGBoost	max_depth = 4, learning_rate = 0,03, subsample = 0,8, colsample_bytree = 0,8, hingga 600 pohon, *early stopping* sabar 40	*Random search* pada data validasi
Naive	$\hat{r}_{t+1} = 0$ (harga tetap)	–

3.7 Evaluasi

Prinsip evaluasi: data uji tidak pernah dipakai untuk pelatihan maupun penyetelan; semua model dievaluasi pada baris uji yang sama; metrik dihitung pada satuan harga hasil rekonstruksi dari *log-return*; dan *baseline* naive menjadi pembanding wajib karena MAPE/RMSE pada H4 tampak kecil untuk semua model.

Metrik akurasi titik: **MAE, RMSE, MAPE** (lazim pada studi sejenis [2], [12]), **MAE relatif** (relMAE = MAE_model / MAE_naive; < 1 berarti lebih baik dari naive; skala bebas mengikuti [21]), dan **R^2_OOS** pada ruang *log-return*

terhadap prediksi nol. Metrik arah: **directional accuracy** (acuan acak ≈ 50%). Perbedaan akurasi antar model diuji dengan **uji Diebold–Mariano** [20] berikut koreksi sampel kecil Harvey–Leybourne–Newbold [24]; karena delapan uji dilakukan sekaligus (4 model vs naive, 2 ablasi B vs A, 2 LSTM vs XGBoost), nilai-p dikoreksi **Holm–Bonferroni**. Kontribusi indikator dianalisis melalui *feature importance* XGBoost (gain), *permutation importance* pada kedua model, dan *drop-group ablation*. Kriteria keberhasilan: model dianggap berguna jika relMAE < 1 dan uji DM vs naive signifikan (p Holm < 0,05); Ichimoku dianggap menambah nilai jika skenario B lebih baik dari A dan signifikan. Jika kriteria tidak terpenuhi, kesimpulan yang dilaporkan adalah "tidak ada bukti peningkatan" dalam kerangka efisiensi pasar [23], yang tetap merupakan kontribusi ilmiah yang sah.

3.8 Hasil Pilot (Uji Kelayakan Pipeline)

Pipeline dijalankan satu kali pada dataset ini dengan konfigurasi awal tanpa penyetelan, satu *seed*, pada 1.742 bar data uji (17 Mei 2017 – 19 Juni 2018). MAE *baseline* naive 0,0477 USD; XGBoost-A 0,0477 (relMAE 1,0006), XGBoost-B 0,0477 (1,0012), LSTM-A 0,0483 (1,0119), dan LSTM-B 0,0483 (1,0129); akurasi arah 48,5%–49,5%. Tidak ada model yang mengalahkan naive dan delapan uji Diebold–Mariano setelah koreksi Holm tidak signifikan pada $\alpha = 0{,}05$ (p terkecil 0,5645). Hasil ini konsisten dengan sifat harga H4 yang mendekati *random walk*, dan menunjukkan bahwa (1) pipeline berjalan tanpa kebocoran data, serta (2) peningkatan dari naive, jika ada, akan kecil dan harus dibuktikan dengan uji statistik. Penelitian dirancang agar hasil seperti ini tetap dapat dilaporkan secara sah (lihat hipotesis di 1.4).

3.9 Alat dan Lingkungan

Python 3.12, pandas, NumPy, scikit-learn, XGBoost, TensorFlow/Keras, MetaTrader 5 (Python API) untuk tahap lanjutan, Git/GitHub untuk dokumentasi. Seluruh kode ada di **06-Kode/**.

3.10 Jadwal Penelitian (Usulan)

Tabel 3.5. Jadwal penelitian (usulan)

Minggu	Kegiatan
9	Finalisasi dataset, analisis eksplorasi data (EDA)
10	Validasi rekayasa fitur dan *baseline*
11	Pelatihan dan penyetelan LSTM dan XGBoost
12	Evaluasi lengkap: ablasi, Diebold–Mariano, *feature importance*
13	**Presentasi 1:** latar belakang, celah riset, metodologi, hasil awal
14	**Presentasi 2:** hasil eksperimen utama
15	**Presentasi 3:** analisis, pembahasan, *forward test* demo (jika dilakukan)
16	**Presentasi final** dan penyerahan draft paper

Sesuaikan dengan silabus mata kuliah.

3.11 Risiko dan Mitigasi

Tabel 3.6. Risiko penelitian dan mitigasinya

Risiko	Mitigasi
Model tidak mengalahkan naive	Dilaporkan sebagai temuan; dianalisis lewat uji DM, ablasi, dan pembahasan efisiensi pasar
Kebocoran data	Split kronologis, penskalaan hanya dari *train*, Chikou tanpa data masa depan, uji pada data acak
Perubahan rezim pasar (2011–2016 bergejolak vs test 2017–2018 tenang)	Pembahasan per sub-periode pada data test; perluasan data ke 2026
Variasi hasil LSTM antar *seed*	5 *seed*, laporkan rerata ± simpangan baku
Keterbatasan lisensi data	Cantumkan sumber, gunakan untuk akademik non-komersial

DAFTAR PUSTAKA

[1] D. N. Gono, H. Napitupulu, and Firdaniza, "Silver price forecasting using extreme gradient boosting (XGBoost) method," *Mathematics*, vol. 11, no. 18, p. 3813, 2023, doi: 10.3390/math11183813.

[2] Y. E. Gür, "Comparative analysis of deep learning models for silver price prediction: CNN, LSTM, GRU and hybrid approach," *Akdeniz İİBF Dergisi*, vol. 24, no. 1, pp. 1–13, 2024.

[3] B. Jin and X. Xu, "Gaussian process regression-based silver price forecasts," *J. Uncertain Syst.*, vol. 18, no. 1, 2024, doi: 10.1142/S1752890924500132.

[4] P. Foroutan and S. Lahmiri, "Deep learning systems for forecasting the prices of crude oil and precious metals," *Financial Innovation*, vol. 10, no. 1, 2024, doi: 10.1186/s40854-024-00637-z.

[5] S. B. Jabeur, S. Mefteh-Wali, and J.-L. Viviani, "Forecasting gold price with the XGBoost algorithm and SHAP interaction values," *Ann. Oper. Res.*, vol. 334, pp. 679–699, 2024, doi: 10.1007/s10479-021-04187-w.

[6] M. Küçük, F. Çebi, and A. T. Tekin, "XAU/USD price prediction using deep learning: Hyperparameter optimization with Bayesian, Grey-Wolf and genetic algorithms," in *Intelligent and Fuzzy Systems (INFUS 2025)*, Lecture Notes in Networks and Systems, vol. 1529. Cham, Switzerland: Springer, 2025, doi: 10.1007/978-3-031-97992-7_12.

[7] A. Saini, R. K. Singh, and P. Sinha, "Forecasting gold price using hybrid deep neural network LSTM-autoencoder," *Discover Artif. Intell.*, vol. 5, art. 281, 2025, doi: 10.1007/s44163-025-00464-w.

[8] S. Deng and A. Sakurai, "Short-term foreign exchange rate trading based on the support/resistance level of Ichimoku Kinkohyo," IEEE conference publication, 2014.

[9] Y. Cahyadi, "Ichimoku Kinko Hyo: Keunikan dan penerapannya dalam strategi perdagangan valuta asing (studi kasus pada pergerakan USD/JPY dan EUR/USD)," *BINUS Bus. Rev.*, vol. 3, no. 1, pp. 480–492, 2012, doi: 10.21512/bbr.v3i1.1336.

[10] L. P. Utomo and D. Setiawan, "Analisis perdagangan foreign exchange dengan pendekatan Ichimoku Kinko Hyo," *J. Bisnis Kewirausahaan*, vol. 16, no. 1, 2020.

[11] H. Mukti, "Penerapan analisis teknikal Ichimoku no Kinko Hyo pada saham JII (Jakarta Islamic Index)," Skripsi, UIN Sunan Kalijaga, Yogyakarta, 2018.

[12] A. Tholib, N. K. Agusmawati, and F. Khoiriyah, "Prediksi harga emas menggunakan metode LSTM dan GRU," *J. Inform. Tek. Elektro Terapan (JITET)*, vol. 11, no. 3, pp. 620–627, 2023, doi: 10.23960/jitet.v11i3.3250.

[13] M. Marwondo and T. Hidayah, “Perbandingan algoritma long short-term memory (LSTM) dan gated recurrent unit (GRU) untuk prediksi harga emas dunia,” *In Search*, vol. 21, no. 2, pp. 230–239, 2023, doi: 10.37278/insearch.v21i2.600.

[14] T. G. Lasijan, R. Santoso, and A. R. Hakim, “Prediksi harga emas dunia menggunakan metode long-short term memory,” *J. Gaussian*, vol. 12, no. 2, pp. 287–295, 2023, doi: 10.14710/j.gauss.12.2.287-295.

[15] A. F. Buana, A. N. Permana, H. Zulfa, A. Subarkah, and A. Z. Kamalia, “Analisis komparatif kinerja LSTM dan SVR dalam prediksi harga emas berjangka,” *J. Ilmu Komput. dan Inform.*, vol. 2, no. 3, pp. 73–80, 2026.

[16] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Comput.*, vol. 9, no. 8, pp. 1735–1780, 1997.

[17] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.

[18] J. W. Wilder, *New Concepts in Technical Trading Systems*. Greensboro, NC, USA: Trend Research, 1978.

[19] A. Elder, *Trading for a Living*. New York, NY, USA: Wiley, 1993.

[20] F. X. Diebold and R. S. Mariano, “Comparing predictive accuracy,” *J. Bus. Econ. Stat.*, vol. 13, no. 3, pp. 253–263, 1995.

[21] R. J. Hyndman and A. B. Koehler, “Another look at measures of forecast accuracy,” *Int. J. Forecast.*, vol. 22, no. 4, pp. 679–688, 2006.

[22] Dukascopy Bank SA, “Historical tick data, XAG/USD,” via FX-Data, “FX-Data-XAGUSD-DS,” GitHub repository. [Online]. Available: https://github.com/FX-Data/FX-Data-XAGUSD-DS (accessed Oct. 2026).

[23] E. F. Fama, “Efficient capital markets: A review of theory and empirical work,” *J. Finance*, vol. 25, no. 2, pp. 383–417, 1970.

[24] D. Harvey, S. Leybourne, and P. Newbold, “Testing the equality of prediction mean squared errors,” *Int. J. Forecast.*, vol. 13, no. 2, pp. 281–291, 1997.