Prediksi Harga XAG/USD H4: Perbandingan LSTM dan XGBoost dengan Indikator Teknikal dan Ichimoku Kinko Hyo

Shahzada Sabih Anandian Hartanto
Program Studi Informatika, Fakultas Ilmu Komputer
Universitas Pembangunan Nasional "Veteran" Jawa Timur
Surabaya, Indonesia
23081010209@student.upnjatim.ac.id

***Abstrak*——** Perak (XAG/USD) memiliki karakter ganda sebagai logam mulia sekaligus logam industri sehingga harganya sangat fluktuatif. Penelitian prediksi harga logam mulia umumnya memakai data harian dan harga historis murni, sedangkan indikator teknikal yang dipakai praktisi, yaitu Ichimoku Kinko Hyo dan Bulls & Bears Power (Elder Ray), jarang dievaluasi sebagai fitur model *machine learning* untuk perak. Penelitian ini membandingkan *Long Short-Term Memory* (LSTM) dan XGBoost pada timeframe H4 dengan dua skenario fitur: (A) indikator konvensional (Moving Average, RSI, MACD, Bulls & Bears Power) dan (B) skenario A ditambah lima komponen Ichimoku Kinko Hyo. Dataset berisi 11.690 bar H4 (Januari 2011–Juni 2018) yang dibangun dari data tick Dukascopy, dengan 1.742 bar sebagai data uji. Evaluasi memakai MAE, RMSE, MAPE, akurasi arah, MAE relatif, dan uji Diebold–Mariano dengan koreksi Holm, ditambah analisis *feature importance*. Pada konfigurasi awal tanpa penyetelan, seluruh model belum mengalahkan *baseline* naive: MAE 0,0477 USD untuk XGBoost dan 0,0483 USD untuk LSTM, dengan akurasi arah sekitar 49%. Seluruh delapan uji Diebold–Mariano tidak signifikan pada $\alpha = 0{,}05$ setelah koreksi Holm (p terkecil 0,5645), sehingga penambahan Ichimoku tidak terbukti meningkatkan akurasi pada tahap ini. Hasil ini konsisten dengan sifat harga H4 yang mendekati *random walk* dan menjadi *baseline* kuantitatif bagi tahap penyetelan hiperparameter serta *forward testing*.

Kata Kunci*—XAG/USD, prediksi harga, LSTM, XGBoost, Ichimoku Kinko Hyo, Elder Ray, uji Diebold–Mariano.*

***Abstract*——** Silver (XAG/USD) has a dual character as both a precious and an industrial metal, which makes its price highly volatile. Studies on precious-metal price prediction mostly rely on daily data and historical prices alone, while technical indicators used by practitioners, namely Ichimoku Kinko Hyo and Bulls & Bears Power (Elder Ray), are rarely evaluated as machine-learning features for silver. This study compares Long Short-Term Memory (LSTM) and XGBoost on the H4 timeframe under two feature scenarios: (A) conventional indicators (Moving Average, RSI, MACD, Bulls & Bears Power) and (B) scenario A plus the five components of Ichimoku Kinko Hyo. The dataset contains 11,690 H4 bars (January 2011–June 2018) derived from Dukascopy tick data, with 1,742 bars held out for testing. Evaluation uses MAE, RMSE, MAPE, directional accuracy, relative MAE, and the Diebold–Mariano test with Holm correction, complemented by feature-importance analysis. Under the untuned initial configuration, no model beats the naive baseline: MAE is 0.0477 USD for XGBoost and 0.0483 USD for LSTM, with directional accuracy around 49%. All eight Diebold–Mariano tests are non-significant at $\alpha = 0.05$ after Holm correction (smallest $p = 0.5645$), so adding Ichimoku is not shown to improve accuracy at this stage. The result is consistent with H4 prices behaving close to a random walk and provides a quantitative baseline for hyperparameter tuning and forward testing.

I. PENDAHULUAN

Perak diperdagangkan sebagai logam mulia sekaligus dipakai luas sebagai bahan baku industri. Karena dipengaruhi sentimen aset lindung nilai dan permintaan industri, harga perak cenderung lebih fluktuatif dibanding emas. Prediksi harga yang akurat bernilai bagi trader, investor, maupun pelaku industri, tetapi pasar keuangan dikenal sulit diprediksi karena harga telah mencerminkan informasi yang tersedia [23]. Konsekuensinya, model prediksi perlu dibandingkan dengan *baseline* sederhana agar klaim akurasinya bermakna.

Penelitian prediksi harga perak berbasis *machine learning* masih terbatas. Gono dkk. menerapkan XGBoost untuk harga perak [1], Gür membandingkan CNN, LSTM, GRU, dan model hibrida [2], sedangkan Jin dan Xu memakai *Gaussian process regression* [3]. Studi pada emas dan logam mulia [4]–[7] serta riset lokal berbahasa Indonesia [12]–[15] menunjukkan bahwa model *tree ensemble* dan *deep learning* sama-sama kompetitif. Namun, dari literatur yang ditinjau, penelitian yang khusus membahas XAG/USD dengan indikator teknikal praktisi sangat sedikit.

Praktisi memakai Ichimoku Kinko Hyo, RSI, MACD, dan Bulls & Bears Power (Elder Ray) [18], [19]. Ichimoku di literatur lokal baru dikaji sebagai aturan perdagangan manual [9]–[11], dan di literatur internasional sebagian besar sebagai aturan berbasis dukungan–resistensi [8]. Selain itu, mayoritas studi memakai data harian, sedangkan timeframe H4 menyediakan observasi jauh lebih banyak.

Berdasarkan celah tersebut, penelitian ini membandingkan LSTM [16] dan XGBoost [17] pada XAG/USD timeframe H4 dengan dua skenario fitur: (A) indikator konvensional dan (B) indikator konvensional ditambah Ichimoku Kinko Hyo. Rancangan 2×2 memungkinkan pengukuran langsung kontribusi Ichimoku, dan semua model dibandingkan terhadap *baseline* naive dengan uji signifikansi statistik [20]. Kontribusi penelitian ini adalah: (1) evaluasi terkontrol kontribusi Ichimoku dan Elder Ray sebagai fitur pada model *machine learning* untuk perak; (2) rancangan 2×2 dengan *baseline* naive, uji Diebold–Mariano, dan pencegahan kebocoran data yang dapat direplikasi; serta (3) dataset XAG/USD H4 beserta kode yang terbuka.

II. KAJIAN LITERATUR

A. Prediksi Harga Perak dan Logam Mulia

Gono dkk. [1] memakai XGBoost pada harga perak harian dengan variabel pendukung harga emas, platinum, dan kurs USD/EUR, dan melaporkan performa baik untuk prediksi jangka pendek. Gür [2] membandingkan CNN, LSTM, GRU, dan model hibrida pada harga perak dengan hasil terbaik pada model hibrida CNN-LSTM-GRU ($R^2 \approx 0{,}99$). Jin dan Xu [3] memakai *Gaussian process regression*

sebagai alternatif probabilistik. Ketiganya tidak mengevaluasi indikator teknikal praktisi sebagai fitur.

Pada aset lain, Foroutan dan Lahmiri [4] mengevaluasi sistem *deep learning* untuk minyak mentah dan logam mulia, Jabeur dkk. [5] memakai XGBoost dengan SHAP untuk emas, Küçük dkk. [6] membandingkan beberapa *optimizer* pada XAU/USD harian, dan Saini dkk. [7] menguji LSTM-autoencoder untuk emas. Studi lokal [12]–[15] umumnya membandingkan LSTM dengan GRU atau SVR pada harga emas dan belum melibatkan Ichimoku.

B. Ichimoku Kinko Hyo dan Elder Ray

Ichimoku Kinko Hyo terdiri atas Tenkan-sen, Kijun-sen, Senkou Span A, Senkou Span B, dan Chikou Span [8]–[11]. Deng dan Sakurai [8] memakai level dukungan–resistensi Ichimoku sebagai aturan perdagangan, sedangkan Cahyadi [9], Utomo dan Setiawan [10], serta Mukti [11] mengkajinya secara manual pada forex dan saham. Elder Ray, yang terdiri atas Bulls Power dan Bears Power [19], juga merupakan indikator praktisi yang belum dievaluasi sebagai fitur model untuk perak.

C. LSTM dan XGBoost

LSTM adalah arsitektur *recurrent neural network* dengan gerbang *input*, *forget*, dan *output* yang mampu menangkap dependensi jangka panjang pada data sekuensial [16]. XGBoost adalah implementasi *gradient boosted decision trees* dengan regularisasi dan penanganan *sparsity* [17]; model ini cepat dilatih, bekerja pada fitur tabular, dan menyediakan *feature importance* yang memudahkan interpretasi [1], [5].

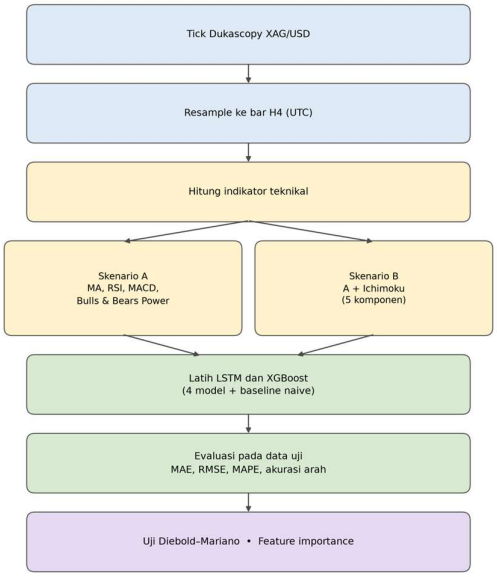
D. Celah Penelitian

Dari literatur yang ditinjau, teridentifikasi empat celah: (G1) prediksi harga perak berbasis *machine learning* masih sedikit, khususnya di literatur lokal; (G2) Ichimoku dan Elder Ray belum dievaluasi sebagai fitur model LSTM/XGBoost untuk perak; (G3) belum ditemukan studi yang membandingkan LSTM dan XGBoost dengan fitur identik disertai uji ablasi, *baseline* naive, dan uji signifikansi; serta (G4) studi yang ditinjau umumnya memakai data harian, bukan timeframe H4.

III. METODOLOGI

A. Desain Penelitian

Penelitian ini merupakan eksperimen kuantitatif dengan rancangan 2×2: dua model (LSTM dan XGBoost) × dua skenario fitur (A dan B), ditambah *baseline* naive sebagai pembanding. Alur penelitian ditunjukkan pada Gambar 1.



GAMBAR 1. Alur penelitian: dari data tick hingga evaluasi dan *forward testing*.

B. Dataset

Dataset berupa 11.690 bar H4 XAG/USD (UTC) periode 20 Januari 2011 hingga 19 Juni 2018, dibangun dari data tick Dukascopy Bank SA melalui mirror publik FX-Data [22]. Harga yang dipakai adalah harga tengah (*mid*) dari bid dan ask. Kolom dataset meliputi time, open, high, low, close, tick_volume, dan avg_spread. Pemeriksaan kualitas menunjukkan tidak ada duplikat waktu, tidak ada nilai kosong, dan tidak ada pelanggaran konsistensi OHLC.

Sebanyak 78 bar awal dibuang untuk periode pemanasan indikator (Ichimoku memerlukan 52 + 26 bar), sehingga tersisa 11.612 baris siap pakai. Pembagian data dilakukan secara kronologis, bukan acak, untuk mencegah kebocoran informasi masa depan, dengan komposisi 70% latih, 15% validasi, dan 15% uji sebagaimana Tabel I.

TABEL I. Pembagian Data Kronologis

Subset	Rentang	Jumlah
Latih (70%)	15 Mar 2011 – 14 Apr 2016	8.128
Validasi (15%)	14 Apr 2016 – 17 Mei 2017	1.742
Uji (15%)	17 Mei 2017 – 19 Jun 2018	1.742

C. Rekayasa Fitur

Semua fitur dibuat *scale-free* dengan membagi nilainya terhadap harga *close* agar model tidak terganggu ketika harga mencapai level yang belum pernah ada di data latih. Skenario A memuat *log-return* bar sebelumnya, jarak Moving Average, RSI(14), MACD, serta Bulls dan Bears Power. Skenario B memuat seluruh fitur skenario A ditambah lima komponen Ichimoku dalam bentuk jarak terhadap harga *close*. Tabel II merangkum komposisi fitur.

TABEL II. Komposisi Fitur pada Skenario A dan B

Kelompok	Fitur	A	B
Dasar	ret_1	✓	✓
Moving Average	sma20_dist, sma50_dist, sma20_50_diff	✓	✓
RSI	rsi14	✓	✓
MACD	macd, macd_signal, macd_hist	✓	✓
Bulls & Bears	bull_power, bear_power	✓	✓
Ichimoku	tenkan_dist, kijun_dist, spanA_dist, spanB_dist, chikou_diff	–	✓

Pencegahan kebocoran data. Pada grafik, Chikou Span digambar dengan menggeser harga *close* 26 bar ke belakang sehingga memakai data masa depan. Pada penelitian ini fitur Chikou didefinisikan sebagai selisih harga *close* sekarang dengan *close* 26 bar lalu, yang bermakna sama tetapi hanya memakai informasi masa lalu. Awan Ichimoku pada bar saat ini diambil dari hasil hitungan 26 bar sebelumnya.

D. Variabel Target

Target prediksi adalah *log-return* bar berikutnya, $r_{t+1} = \ln(C_{t+1}/C_t)$. Harga diprediksi melalui rekonstruksi $\hat{C}_{t+1} = C_t \cdot \exp(\hat{r}_{t+1})$ sehingga metrik tetap dihitung dalam satuan harga. Pendekatan ini dipilih karena model berbasis pohon tidak dapat mengekstrapolasi ke rentang harga di luar data latih, padahal perak melewati rentang harga yang sangat lebar.

E. Konfigurasi Model

LSTM memakai satu lapisan dengan 64 unit, *dropout* 0,2, Adam (lr 1e-3), *batch* 64, jendela 48 bar (delapan hari), dan *early stopping* dengan kesabaran 5. XGBoost memakai max_depth = 4, learning_rate = 0,03, subsample = 0,8, colsample_bytree = 0,8, hingga 600 pohon, dan *early stopping* dengan kesabaran 40. *Baseline* naive memprediksi $\hat{r}_{t+1} = 0$, yaitu harga tetap.

F. Metrik Evaluasi

Evaluasi memakai MAE, RMSE, dan MAPE pada satuan harga, akurasi arah, serta MAE relatif terhadap naive (relMAE < 1 berarti lebih baik dari naive) mengikuti anjuran [21]. R^2_OOS dihitung pada ruang *log-return* terhadap prediksi nol. Perbedaan akurasi antar model diuji dengan uji Diebold–Mariano [20] memakai koreksi sampel kecil Harvey–Leybourne–Newbold [24], dan nilai-p dikoreksi dengan prosedur Holm karena delapan uji dilakukan sekaligus. Data uji tidak pernah dipakai untuk pelatihan maupun penyetelan.

IV. Hasil dan Pembahasan

A. Hasil Kuantitatif

Tabel III merangkum kinerja seluruh model pada 1.742 bar data uji (17 Mei 2017 – 19 Juni 2018). MAE *baseline* naive sebesar 0,0477 USD. XGBoost-A menghasilkan MAE 0,0477 USD (relMAE 1,0006), XGBoost-B 0,0477 USD (relMAE 1,0012), LSTM-A 0,0483 USD (relMAE 1,0119), dan LSTM-B 0,0483 USD (relMAE 1,0129). Dengan demikian, tidak ada model yang mengalahkan naive.

TABEL III. Kinerja Model pada Data Uji (1.742 Bar)

Model	MAE	RMSE	MAPE (%)	Arah (%)	relMAE	R^2_OOS
Naive	0,0477	0,0702	0,2846	–	1,0000	0,00000
XGBoost-A	0,0477	0,0702	0,2848	49,48	1,0006	-0,00011
LSTM-A	0,0483	0,0705	0,2879	49,02	1,0119	-0,00964
XGBoost-B	0,0477	0,0702	0,2850	48,51	1,0012	-0,00031
LSTM-B	0,0483	0,0706	0,2882	49,02	1,0129	-0,01114

Akurasi arah seluruh model berada pada kisaran 48,5%–49,5%, setara tebakan acak untuk klasifikasi biner. Nilai R^2_OOS bernilai negatif sangat kecil (−0,0111 hingga −0,0001), yang berarti prediksi model tidak lebih informatif daripada prediksi nol.

B. Uji Signifikansi Diebold–Mariano

Tabel IV memuat hasil delapan uji Diebold–Mariano setelah koreksi Holm. Tidak satu pun uji signifikan pada $\alpha = 0,05$; nilai-p terkecil adalah 0,5645. Dengan demikian, hipotesis bahwa model lebih akurat daripada naive tidak dapat diterima, penambahan Ichimoku tidak terbukti meningkatkan akurasi, dan perbedaan LSTM dengan XGBoost tidak signifikan secara statistik.

TABEL IV. Uji Diebold–Mariano (Koreksi Holm, m = 8)

Uji	DM	p	p (Holm)	Signifikan
XGB-A vs Naive	0,035	0,9719	1,0000	Tidak
LSTM-A vs Naive	1,643	0,1003	0,5645	Tidak
XGB-B vs Naive	0,204	0,8382	1,0000	Tidak
LSTM-B vs Naive	1,695	0,0901	0,5645	Tidak
XGB-A vs XGB-B	0,436	0,6631	1,0000	Tidak
LSTM-A vs LSTM-B	0,712	0,4768	1,0000	Tidak
LSTM-A vs XGB-A	1,789	0,0736	0,5645	Tidak
LSTM-B vs XGB-B	1,808	0,0706	0,5645	Tidak

C. Kontribusi Indikator

Pada skenario A, kontribusi *gain* XGBoost terbesar berasal dari sma50_dist (12,5%), macd_signal (11,3%), bear_power (11,2%), dan bull_power (9,9%). Pada skenario B, komponen Ichimoku mengambil porsi teratas, yaitu spanB_dist (8,7%), tenkan_dist (7,2%), kijun_dist (7,1%), dan spanA_dist (7,1%). Namun, karena tidak ada model yang mengalahkan naive, angka *feature importance* ini belum dapat ditafsirkan sebagai kontribusi indikator yang bermakna; nilainya terutama mencerminkan pemisahan pohon pada derau.

D. Pembahasan

Early stopping XGBoost berhenti sangat dini (iterasi 0 pada skenario B dan iterasi 10 pada skenario A), yang menandakan hampir tidak ada sinyal yang dapat dipelajari dari fitur pada data validasi. Hasil ini konsisten dengan hipotesis pasar efisien [23]: pada timeframe H4, perubahan harga mendekati *random walk* sehingga sulit diprediksi dari harga historis dan indikator turunannya.

Faktor kedua adalah perbedaan rezim. Data latih (2011–2016) memuat gejolak besar dengan harga bergerak dari sekitar 49 USD turun ke sekitar 14 USD, sedangkan data uji (Mei 2017 – Juni 2018) berada pada periode tenang dengan harga bergerak sempit di kisaran 16–18 USD. Pada rezim volatilitas rendah, naive sangat sulit dikalahkan karena perubahan antar bar sangat kecil dibandingkan skala harga.

Temuan ini bukan kegagalan penelitian. Sebagaimana dinyatakan pada rancangan evaluasi, hasil yang gagal menolak hipotesis nol tetap merupakan kontribusi ilmiah yang sah, dan justru memberikan *baseline* kuantitatif yang jujur bagi penelitian lanjutan. Nilai pentingnya adalah bahwa klaim berlebihan mengenai keunggulan indikator praktisi dapat diuji dan, pada konfigurasi ini, tidak terkonfirmasi.

V. KESIMPULAN

Penelitian ini membandingkan LSTM dan XGBoost pada prediksi harga XAG/USD timeframe H4 dengan dua skenario fitur indikator teknikal. Pada konfigurasi awal tanpa penyetelan, seluruh model menghasilkan galat yang praktis setara dengan *baseline* naive (selisih MAE 0,06%–1,29%) dan akurasi arah sekitar 49%, serta tidak satu pun perbedaan akurasi yang signifikan secara statistik setelah koreksi Holm. Penambahan lima komponen Ichimoku Kinko Hyo belum terbukti meningkatkan akurasi.

Keterbatasan penelitian ini adalah penggunaan konfigurasi awal tanpa penyetelan hiperparameter, satu *seed* untuk LSTM, dan data uji pada rezim volatilitas rendah. Penelitian lanjutan akan melakukan penyetelan hiperparameter pada data validasi, pengulangan LSTM dengan lima *seed*, analisis per sub-periode, perluasan data hingga 2026, serta *forward testing* pada akun demo untuk menguji konsistensi hasil di luar sampel.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada dosen pengampu mata kuliah Riset Informatika Program Studi Informatika, Fakultas Ilmu Komputer, Universitas Pembangunan Nasional “Veteran” Jawa Timur atas arahan dalam penyusunan penelitian ini.

DAFTAR PUSTAKA

[1] D. N. Gono, H. Napitupulu, and Firdaniza, “Silver price forecasting using extreme gradient boosting (XGBoost) method,” *Mathematics*, vol. 11, no. 18, p. 3813, 2023, doi: 10.3390/math11183813.

[2] Y. E. Gür, “Comparative analysis of deep learning models for silver price prediction: CNN, LSTM, GRU and hybrid approach,” *Akdeniz İİBF Dergisi*, vol. 24, no. 1, pp. 1–13, 2024.

[3] B. Jin and X. Xu, “Gaussian process regression-based silver price forecasts,” *J. Uncertain Syst.*, vol. 18, no. 1, 2024, doi: 10.1142/S1752890924500132.

[4] P. Foroutan and S. Lahmiri, “Deep learning systems for forecasting the prices of crude oil and precious metals,” *Financial Innovation*, vol. 10, no. 1, 2024, doi: 10.1186/s40854-024-00637-z.

[5] S. B. Jabeur, S. Mefteh-Wali, and J.-L. Viviani, “Forecasting gold price with the XGBoost algorithm and SHAP interaction values,” *Ann. Oper. Res.*, vol. 334, pp. 679–699, 2024, doi: 10.1007/s10479-021-04187-w.

[6] M. Küçük, F. Çebi, and A. T. Tekin, “XAU/USD price prediction using deep learning: Hyperparameter optimization with Bayesian, Grey-Wolf and genetic algorithms,” in *Intelligent and Fuzzy Systems (INFUS 2025)*, Lecture Notes in Networks and Systems, vol. 1529. Cham, Switzerland: Springer, 2025, doi: 10.1007/978-3-031-97992-7_12.

[7] A. Saini, R. K. Singh, and P. Sinha, “Forecasting gold price using hybrid deep neural network LSTM-autoencoder,” *Discover Artif. Intell.*, vol. 5, art. 281, 2025, doi: 10.1007/s44163-025-00464-w.

[8] S. Deng and A. Sakurai, “Short-term foreign exchange rate trading based on the support/resistance level of Ichimoku Kinkohyo,” in *Proc. IEEE Conf.*, 2014.

[9] Y. Cahyadi, “Ichimoku Kinko Hyo: Keunikan dan penerapannya dalam strategi perdagangan valuta asing (studi kasus pada pergerakan USD/JPY dan EUR/USD),” *BINUS Bus. Rev.*, vol. 3, no. 1, pp. 480–492, 2012, doi: 10.21512/bbr.v3i1.1336.

[10] L. P. Utomo and D. Setiawan, “Analisis perdagangan foreign exchange dengan pendekatan Ichimoku Kinko Hyo,” *J. Bisnis Kewirausahaan*, vol. 16, no. 1, 2020.

[11] H. Mukti, “Penerapan analisis teknikal Ichimoku no Kinko Hyo pada saham JII (Jakarta Islamic Index),” Skripsi, UIN Sunan Kalijaga, Yogyakarta, 2018.

[12] A. Tholib, N. K. Agusmawati, and F. Khoiriyah, “Prediksi harga emas menggunakan metode LSTM dan GRU,” *J. Inform. Tek. Elektro Terapan (JITET)*, vol. 11, no. 3, pp. 620–627, 2023, doi: 10.23960/jitet.v11i3.3250.

[13] M. Marwondo and T. Hidayah, “Perbandingan algoritma long short-term memory (LSTM) dan gated recurrent unit (GRU) untuk prediksi harga emas dunia,” *In Search*, vol. 21, no. 2, pp. 230–239, 2023, doi: 10.37278/insearch.v21i2.600.

[14] T. G. Lasijan, R. Santoso, and A. R. Hakim, “Prediksi harga emas dunia menggunakan metode long-short term memory,” *J. Gaussian*, vol. 12, no. 2, pp. 287–295, 2023, doi: 10.14710/j.gauss.12.2.287-295.

[15] A. F. Buana, A. N. Permana, H. Zulfa, A. Subarkah, and A. Z. Kamalia, “Analisis komparatif kinerja LSTM dan SVR dalam prediksi harga emas berjangka,” *J. Ilmu Komput. dan Inform.*, vol. 2, no. 3, pp. 73–80, 2026.

[16] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Comput.*, vol. 9, no. 8, pp. 1735–1780, 1997.

[17] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.

[18] J. W. Wilder, *New Concepts in Technical Trading Systems*. Greensboro, NC, USA: Trend Research, 1978.

[19] A. Elder, *Trading for a Living*. New York, NY, USA: Wiley, 1993.

[20] F. X. Diebold and R. S. Mariano, “Comparing predictive accuracy,” *J. Bus. Econ. Stat.*, vol. 13, no. 3, pp. 253–263, 1995.

[21] R. J. Hyndman and A. B. Koehler, “Another look at measures of forecast accuracy,” *Int. J. Forecast.*, vol. 22, no. 4, pp. 679–688, 2006.

[22] Dukascopy Bank SA, “Historical tick data, XAG/USD,” via FX-Data, “FX-Data-XAGUSD-DS,” GitHub repository. [Online]. Available: https://github.com/FX-Data/FX-Data-XAGUSD-DS

[23] E. F. Fama, “Efficient capital markets: A review of theory and empirical work,” *J. Finance*, vol. 25, no. 2, pp. 383–417, 1970.

[24] D. Harvey, S. Leybourne, and P. Newbold, “Testing the equality of prediction mean squared errors,” *Int. J. Forecast.*, vol. 13, no. 2, pp. 281–291, 1997.